

# 特微量テンソルによる転移学習と感情辞書を用いた Twitter の感情強度推定

姫野 晋之介<sup>†</sup> 青野 雅樹<sup>‡</sup>

<sup>†</sup> <sup>‡</sup> 豊橋技術科学大学 〒441-8580 愛知県豊橋市 天伯町雲雀ヶ丘 1-1

E-mail: <sup>†</sup> himeno@kde.cs.tut.ac.jp, <sup>‡</sup> aono@tut.jp

**あらまし** Twitter は全世界で 3 億人を超えるユーザを有し、膨大なユーザの意見が蓄積されている。また、ツイートの容易さからリアルタイム性が強く、ユーザの意見が反映されやすいと考えられる。そのため、それらを分析することが強く求められている。その中でユーザが感情を表現したツイートも多く存在し、とても楽しい、少し怒っている、などの感情の強さの程度「感情強度」の情報も含んでいる。しかしながら、ツイートは本文が短く、口語や俗語、略語が多く含まれるため、感情強度を推定することは容易ではない。そのため、これらの性質を考慮し、高精度にツイートの感情強度を推定する手法が必要となる。本研究では、特微量テンソルによる転移学習と感情辞書からの特微量を組合せ、様々な感情強度を高精度に推定する手法を提案し、実験結果を報告する。

**キーワード** Twitter, 転移学習, Attention, 感情辞書, 深層学習

## Estimation of Twitter Emotion Intensity by Using Transfer Learning of Feature Tensors and Emotion Lexicon

Shinnosuke Himeno<sup>†</sup> Masaki Aono<sup>‡</sup>

<sup>†</sup> <sup>‡</sup> Toyohashi University of Technology 1-1 Hibiigaoka, Tempaku-cho, Aichi, 441-8580 Japan

E-mail: <sup>†</sup> himeno@kde.cs.tut.ac.jp, <sup>‡</sup> aono@tut.jp

**Abstract** Twitter has more than 300 million users worldwide, and the opinions of a huge number of users are accumulated. In addition, due to the ease of tweets, real-time nature is strong and the user's opinion is likely to be reflected. Thus, it is strongly required to analyze them. Among them, there are many tweets that the user expressed emotions, including the information on the degree of emotional strength such as very fun and slightly angry. However, it is not easy to estimate the emotional strength because tweets have short texts and may contain many colloquial words, slang words, and abbreviations. Therefore, considering these properties, a method to estimate the emotional strength of tweets with high accuracy is required. In this paper, we propose a method to combine transfer learning based on our original “feature tensors” with the features from emotion lexicon. We then estimate the intensities of various emotions with high accuracy, and finally demonstrate the experiment results.

**Keywords** Twitter, Transfer Learning, Attention, Emotion Lexicon, Deep Learning

### 1. はじめに

現在、SNS (Twitter, Facebook, Flickr など) は人気を集め、インターネット上で広く普及している。そのため、膨大なユーザの意見が蓄積され、それらを分析することが強く求められている。特に、Twitter は全世界で 3 億人を超えるユーザを有している。その書き込み (ツイート) の容易さからリアルタイム性が強く、ユーザの意見が即座に反映されやすい性質を持つ。その中でユーザが感情を表現したツイートも多く存在する。また、ツイートは感情をただ表現するだけでなく、とても楽しい、少し怒っている、などの感情の強さの程度を表した感情強度の情報も含んでいる。これらの感情強度を推定することは商品の感想やニュー

ースへの意見など大規模な意見分析を必要とする分野に応用できると考えられる。しかしながら、ツイートは本文が比較的短く、口語や俗語、略語が多く含まれるため、感情強度を推定することは容易ではない。そのため、これらの性質、すなわち、大規模性、リアルタイム性、短文性、口語・略語性などの性質を考慮し、高精度にツイートの感情強度を推定する手法が必要となる。一方、Twitter の感情分析は国際コンペティション (SemEval) においてポジティブ、ネガティブ、ニュートラルの 3 感情分類からはじまり、2018 年からは、感情を怒り (Anger)、恐れ (Fear)、喜び (Joy)、悲しみ (Sadness) の 4 感情に限定し、ツイートからそれぞれの感情強度を 0.0~1.0 の範囲の感

情値で推定するタスクが始まっている．そこで本研究では，上記 4 感情の強度の推定を行うことを目的とする．感情値は 1.0 に近いほど対象の感情を強く表しており，0.0 に近いほど対象の感情を表していないことを意味する．Fig. 1 に示すようにそれぞれの感情に対して深層学習による感情強度推定モデルを構築し，感情値を推定する手法を提案する．




Fig. 1 本研究における感情強度推定の概要

## 2. 関連研究

これまで，テキストマイニングの分野においてツイートの分析が注目されてきた．ツイートの感情分析の代表的なタスクとしてポジティブ，ネガティブの極性や複数の感情へ分類する研究が行われてきた．このような研究について調査論文も発表されている[1, 2]．特に教師あり学習を使ったツイートの極性分類は Go ら[3]によって提案され，その中で彼らは Naïve Bayes, aximum Entropy, Support Vector Machine などのいくつかの教師あり学習手法を用いた．その後，Bravo-Marquez ら[4]は，複数の感情辞書を用いた手法を提案し，Saif ら[5]は，単語の共起情報を用いて感情进行分类する手法を提案した．近年では，Severyn ら[6]が深層学習による手法を提案した．また，Lu ら[7]は，短いテキストの分類に適した深層学習の構造を提案した．感情分析についての国際コンペティションである SemEval では，2014 年以降，Twitter の感情分析タスクが設けられ，機械学習や word2vec[8, 9]を用いた様々な手法が提案されている[10, 11, 12, 13, 14]．SemEval2017 [15]では，Cliché ら[16]と Hamdan ら[17]が複数の Convolutional Neural Networks (CNN) と複数の Long Short-Term Memory (LSTM)を組み合わせる手法を提案した．

Mohammad らは 2017 年に単語ごとの感情を定めた辞書[18]を公開し，彼らは感情強度推定のための初のデータセット[19]を公開した．また，WASSA-2017[20]にてツイートの感情強度推定タスクでの国際コンペティションを開催し，SemEval 2018 : Task1 Affect in Tweets[21]でも同様のコンペティションを開催した．SemEval 2018 では転移学習を用いた手法や Multi-Attention を用いた手法が提案された．

転移学習は訓練済みのモデルを用いて関連のある別

のタスクに対するモデルの性能を向上させることを目的としている．これは特に Computer Vision (CV)の分野で高い性能を発揮している．例として，ImageNet で事前訓練されたモデルの画像特徴による顔認識[22]や Visual QA[23]が挙げられる．しかしながら，自然言語処理分野において転移学習はあまり普及していない．

## 3. 提案手法

我々は最新の自然言語処理分野において高い性能を発揮している転移学習に注目した．特にツイートの感情分析タスクに関連した訓練済みのモデルを本研究のタスクのために転移学習することで高い精度を得られると考えた．また，これまでのツイートの感情分析タスクにおいて高い性能を発揮してきた感情辞書による特徴量を同時に用いることでより高い精度を得られると考えた．

提案手法の流れについて述べる．まず，ツイート内のテキストに対する前処理（語彙統一など），ツイート内の絵文字に対する前処理（テキスト化）を行う．ここで，訓練データは 4 感情ごとに独立に与えられた英語ツイートと感情値のペアとして与えられる．次に，訓練データを用いて 4 感情のモデルを独立に訓練する．その後，訓練済みモデルによってテストデータの感情値を予測する．ここで，テストデータは 4 感情ごとに独立に与えられた英語ツイートである．訓練の流れ，テストの流れの概要を Figs. 2, 3 に示す．

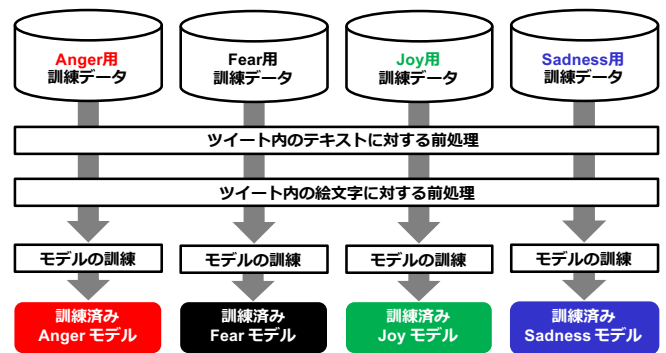


Fig. 2 訓練の流れ

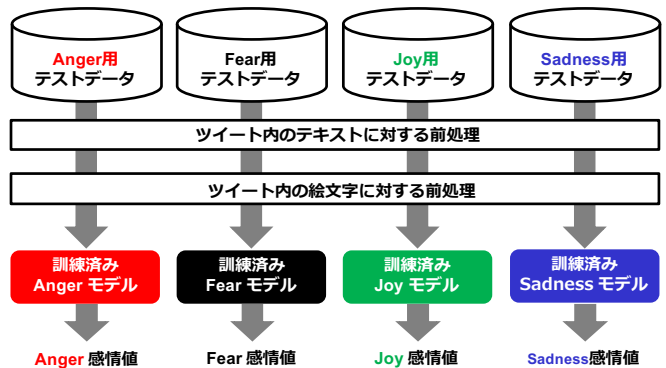


Fig. 3 テストの流れ

### 3.1. ツイート内のテキストに対する前処理

表記揺れや未知語を削減するために、ツイートに対して以下のように前処理をした。

- アルファベットの小文字化
- URL を<URL>という文字列に置換
- 3 連続以上の同一文字を 2 連続に統一
- # (ハッシュタグ) の削除

### 3.2. ツイート内の絵文字に対する前処理

ツイート中に出現する絵文字が表す感情をモデルで推定するために、絵文字をそれぞれの感情を表す語に置換する.

### 3.2.1 Anger を表す絵文字

Fig. 4 に示す絵文字を Anger という文字列に置換する.



**Fig. 4 Anger を表す絵文字**

### 3.2.2 Fear を表す絵文字

Fig. 5 に示す絵文字を Fear という文字列に置換する.



Fig. 5 Fear を表す絵文字

### 3.2.3 Joy を表す絵文字

Fig. 6 に示す絵文字を Joy という文字列に置換する.



Fig. 6 Joy を表す絵文字

### 3.2.4 Sadness を表す絵文字

Fig. 7 に示す絵文字を Sadness という文字列に置換する.



**Fig. 7 Sadness** を表す絵文字

### 3.3. 訓練済みモデルと感情辞書による特徴抽出

本節では，訓練済みモデルによる特徴抽出と，訓練済みモデルによる特徴量テンソル抽出，感情辞書による特徴抽出について述べる．

### 3.3.1 訓練済みモデルによる特徴抽出

DeepMoji[24]は、入力ツイートに適した絵文字を推定するモデルであり、全てに絵文字を含む非常に大きな Twitter データセット (約 12.5 億件) によって訓練されている。また、DeepMoji は転移学習によって様々なタスクで高い性能を発揮している。本研究では、訓練済み DeepMoji モデルの Attention 層の出力を DeepMoji 特微量として使用する。DeepMoji モデルの Attention 層の出力  $v$  は入力を  $h_i$ 、Attention weight を  $w_a$  としたとき式(1)で表される。ここで、 $w_a$  は訓練済みモデルから与えられ、 $T$  は全単語数を表す。DeepMoji 特微量は 2304 次元である。

$$\begin{aligned} e_t &= h_t w_a \\ a_t &= \frac{\exp(e_t)}{\sum_{i=1}^T \exp(e_i)} \end{aligned} \quad (1)$$

$$v = \sum_{i=1}^T a_i h_i$$

### 3.3.2 訓練済みモデルによる特徴量テンソル抽出

我々は訓練済みモデルの中間層の出力をテンソルで抽出する「特徴量テンソル」を提案する．特徴量テンソルは転移学習の特性を保ったまま，テンソルで特徴を表現する．特徴量テンソルを用いることで，中間層の出力を CNN や RNN に入力することが可能となる．

本研究では、訓練済み DeepMoji モデルの Attention 層を式(1)から式(2)に変更し、その出力  $V$  を DeepMoji の特徴量テンソルとして使用する. DeepMoji の特徴量テンソルの shape は(100,2304)次元である. DeepMoji の特徴量テンソルの計算の概要を Fig. 8 に示す.

$$\begin{aligned} e_t &= h_t w_a \\ a_t &= \tanh(e_t) \\ V &= h_i \otimes a_i \end{aligned} \quad (2)$$

( $\otimes$ はベクトルの各要素と行列の各行の積)




Fig. 8 DeepMoji の特徴量テンソルの計算の概要

### 3.3.3 感情辞書による特徴抽出

EmoInt[25]は複数の感情辞書を用いた特徴抽出手法である。ツイートに含まれる全単語に対して全感情辞書の値を連結したものを算出し、それらを足し合わせてツイートの EmoInt 特徴量を得る。EmoInt で用いられる感情辞書とそれぞれの値の次元数を Table 1 に示す。Table 1 で示すように EmoInt 特徴量は 133 次元である。

Table 1 EmoInt で用いられる感情辞書

感情辞書名	次元数
AFINN	2
Bing Liu	2
MPQA	2
NRC Affect Intensity	10
NRC Emotion Word level	10
NRC Expanded Emotion	10
NRC Hashtag Emotion	10
NRC Hashtag Sentiment	2
Sentiment140	2
SentiWordNet	2
Negation	1
LIWC	80
合計	133

### 3.4 提案モデル 1

DeepMoji 特徴量と EmoInt 特徴量を用いた提案モデル 1 について述べる。前処理後ツイートからそれぞれの特徴量を抽出、結合し、推定結果を得るために複数の全結合層に入力する。提案モデル 1 の概要を Fig. 9 に示す。提案モデル 1 で使用する各全結合層の入力は 2437 次元である。

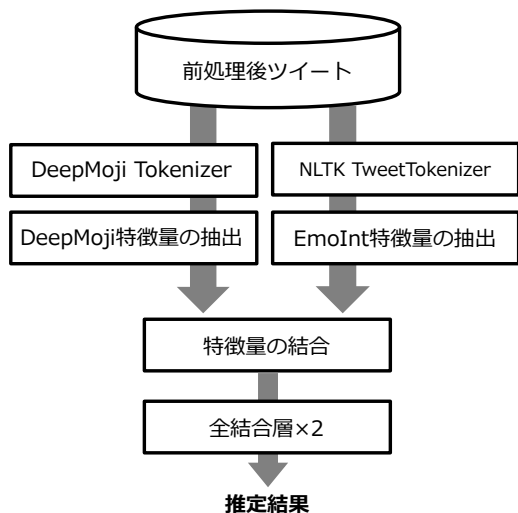


Fig. 9 提案モデル 1 の概要

Table 2 提案モデル 1 で使用する全結合層

Layer	Activation	input	output
Dropout(0.8)	-	2437	2437
Dense	Sigmoid	2437	32
Dense	Sigmoid	32	1

### 3.5 提案モデル 2

DeepMoji の特徴量テンソルと EmoInt 特徴量を用いた提案モデルについて述べる。提案モデル 1 とは違い、DeepMoji の特徴量テンソルを抽出し、畳み込み層に入力する。その後 EmoInt 特徴量と結合し、全結合層によって推定結果を得る。畳み込み層には Kim らが提案した 1 次元の文に対する畳み込み[26]を用いる。この畳み込みを用いることで、重みをかけた各単語のベクトル表現に対して n-gram 単位の特徴を捉えることが可能となる。提案モデル 2 の概要を Fig. 10 に示す。提案モデル 2 で使用する畳み込み層を Table 3 に示す。提案モデル 2 で使用する各全結合層を Table 4 に示す。

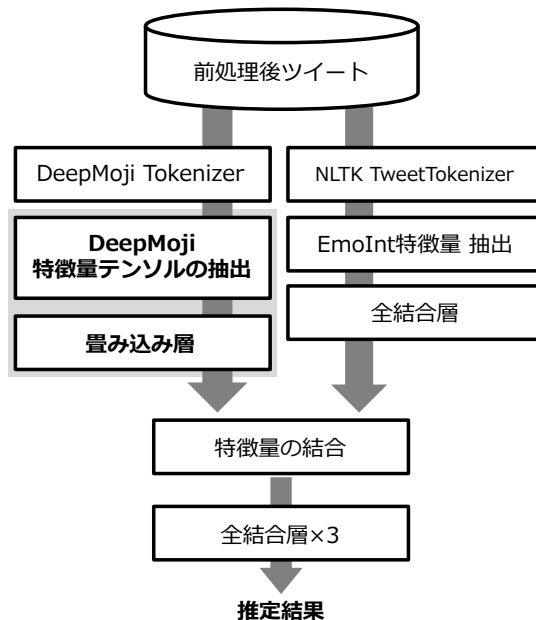


Fig. 10 提案モデル 2 の概要

Table 3 提案モデル 2 で使用する畳み込み層

Layer	kernel	Activation	input	output
Conv1D_1	1	ReLU	(100,2304)	(32,100)
Conv1D_2	2	ReLU	(100,2304)	(32,99)
Conv1D_3	3	ReLU	(100,2304)	(32,98)
Conv1D_4	4	ReLU	(100,2304)	(32,97)
Conv1D_5	5	ReLU	(100,2304)	(32,96)
MaxPooling	-	-	(32,x)	(32,1)
Flatten	-	-	(32,1)	32
Dense	-	Sigmoid	160	64

**Table 4** 提案モデル 2 で使用する全結合層 (二重線  
上は EmoInt 特徴量を入力とする全結合層, 二重線下  
は結合した特徴量を入力とする全結合層)

Layer	Activation	input	output
Dense	Sigmoid	133	64
Dense	Sigmoid	128	32
Dropout(0.8)	-	32	32
Dense	Sigmoid	32	8
Dense	Sigmoid	8	1

## 4 実験

提案手法の有効性を評価するために, 評価実験, 比較実験を行った.

### 4.1 実験用データセット

実験には SemEval 2018 : Task1 Affect in Tweets で使用されたデータセットを用いる. 詳細は Table 5 に示す. Table 5 において開発データセットとは, モデルの未知データに対する推定精度を評価するために用いるデータセットである. モデル訓練中の各エポックで開発データセットを用いたテストを行う. 各エポックの中で最も高い推定精度を得たエポックをモデルの訓練結果とする.

**Table 5** 実験用データセット

	Anger	Fear	Joy	Sadness
訓練	1701	2252	1616	1532
開発	388	389	290	397
テスト	1002	986	1105	975

### 4.2 評価方法

モデルの評価指標には相関係数  $r$  を用いる. 推定結果を  $x$ , 真の値を  $y$  としたとき, 相関係数  $r$  は標本共分散を  $S_{xy}$ , 標本標準偏差を  $S_x$ ,  $S_y$  を用いて, 式(3)で定義される. それぞれの感情モデルの推定値に対して相関係数  $r$  を求め, 平均したものを評価指標とする. 以下では Anger モデルの評価指標  $r$  を  $r(A)$ , 同様に Fear の  $r$  を  $r(F)$ , Joy の  $r$  を  $r(J)$ , Sadness の  $r$  を  $r(S)$  とし,  $r(A)$ ,  $r(F)$ ,  $r(J)$ ,  $r(S)$  の平均を  $\text{avg-}r$  と表記する.

$$r = \frac{S_{xy}}{S_x S_y} \quad (3)$$

### 4.3 評価実験

提案手法で用いる特徴抽出手法に対する評価実験を行う. ここでは, 提案モデル 1, 提案モデル 2 に加えて, DeepMoji 特徴量のみから全結合層によって感情強度を推定するモデル, EmoInt 特徴量のみから全結合層

によって感情強度を推定するモデル, DeepMoji 特徴量のテンソルのみから畳み込み層によって感情強度を推定するモデルを用いる. ここでは, 開発データに対する最も高い推定精度を記載する. 実験結果を Table 6 に示す.

**Table 6** 評価実験結果

手法	avg- $r$	$r(A)$	$r(F)$	$r(J)$	$r(S)$
DeepMoji 特徴量	0.758	0.789	0.685	0.794	0.765
EmoInt 特徴量	0.626	0.577	0.623	0.674	0.628
DeepMoji の 特徴量テンソル	0.759	0.797	0.693	0.774	0.772
提案モデル 1	<b>0.774</b>	0.802	<b>0.724</b>	<b>0.792</b>	0.777
提案モデル 2	0.773	<b>0.803</b>	0.722	0.783	<b>0.783</b>

### 4.4 比較実験

提案モデル 1, 提案モデル 2 の推定精度を評価するために従来手法との比較実験を行う. 比較手法は SemEval 2018 : Task1 Affect in Tweets にて発表された SeerNet<sup>1st</sup>[27], NTUA-SLP<sup>2nd</sup>[28], PlusEmo2Vec<sup>3rd</sup>[29], psyML<sup>4th</sup>[30], TCS Research<sup>5th</sup>[31]である. 比較実験の結果を Table 7 に示す. ただし, 比較手法は同コンペティションが発表した公式の結果を記載する. 提案モデル 1 は SemEval2018 において 3 位, 提案モデル 2 は 6 位の推定精度であった.

**Table 7** 比較実験結果

手法	avg- $r$	$r(A)$	$r(F)$	$r(J)$	$r(S)$
提案モデル 1	0.771	0.811	0.731	0.764	0.778
提案モデル 2	0.761	0.790	0.719	0.778	0.756
SeerNet <sup>1st</sup>	<b>0.799</b>	<b>0.827</b>	<b>0.779</b>	<b>0.792</b>	<b>0.798</b>
NTUA-SLP <sup>2nd</sup>	0.776	0.782	0.758	0.771	0.792
PlusEmo2Vec <sup>3rd</sup>	0.766	0.811	0.728	0.773	0.753
psyML <sup>4th</sup>	0.765	0.788	0.748	0.761	0.761
TCSResearch <sup>5th</sup>	0.764	0.775	0.735	0.770	0.776

## 5 おわりに

本論文では, 特徴量テンソルによる転移学習と感情辞書を用いた Twitter の感情強度推定の手法を提案した. 近年の自然言語処理において高い精度を発揮している転移学習と従来手法である感情辞書による特徴量を結合することで高精度な手法となった. また, 提案モデル 1 は SemEval2018 における 3 位, 提案モデル 2 は 6 位の推定精度であった.

今後の課題として, 他の特徴抽出手法の導入や使用する感情辞書の増強などが挙げられる.

## 謝辞

本研究の一部は, 科研費基盤(B)(課題番号 17H01746)の支援を受けて遂行した.

## 文 献

- [1] A. Giachanou, F. Crestani, Like It or Not: A Survey of Twitter Sentiment Analysis Methods, *ACM Comp. Vol.* 49(2), 41 pp., November 2016.
- [2] N. Felix, Luiz F. S. Coletta, E. R Hruschka, A Survey and Comparative Study of Tweet Sentiment Analysis via Semi-Supervised Learning, *ACM Comp. Surveys* 49(1), 40 pp, 2016.
- [3] A. Go, R. Bhayani, L. Huang, Twitter Sentiment Classification using Distant Supervision, CS224N Project Report, vol.1 12 pp., January 2009.
- [4] F. Bravo-Marquez, M. Mendoza, B. Poblete, Combining Strengths, Emotions and Polarities for Boosting Twitter Sentiment Analysis, *wisdom2013*, 9 pp., August 2013.
- [5] H. Saif, Y. He, M. Fernandez, H. Alani, Contextual semantics for sentiment analysis of Twitter, *Information Processing and Management Vol.* 52(1), pp. 5-19, January 2016.
- [6] A. Severyn, A. Moschitti, Twitter Sentiment Analysis with Deep Convolutional Neural Networks, *SIGIR 2015*, pp. 959-962, August 2015.
- [7] Z. Lu, H. Li, A Deep Architecture for Matching Short Texts, *NIPS'13*, pp. 1367-1375, December 2013.
- [8] T. Mikolov, K. Chen, G. Corrado, J. Dean, Efficient Estimation of Word Representations in Vector Space, *CoRR*, abs/1301.3781, January 2013.
- [9] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, J. Dean, Distributed Representations of Words and Phrases and their Compositionality, *Advances in Neural Information Processing Systems 26*, pages 3111–3119, December 2013.
- [10] M. Hagen, M. Potthast, M. Büchner B. Stein, Webis: An Ensemble for Twitter Sentiment Detection, *SemEval 2015*, 8 pp., June 2015.
- [11] S. Giorgis, A. Rousas John Pavlopoulos, P. Malakasiotis, I. Androutsopoulos, aueb.twitter.sentiment at SemEval-2016 Task 4: A Weighted Ensemble of SVMs for Twitter Sentiment Analysis, *SemEval 2016*, pp. 96-99, June 2016.
- [12] J. Deriu, M. Gonzenbach, F. Uzdilli, A. Lucchi, V. De Luca, M. Jaggi, SwissCheese at SemEval-2016 Task 4: Sentiment Classification Using an Ensemble of Convolutional Neural Networks with Distant Supervision, *SemEval 2016*, pp. 1124-1128, 2016.
- [13] M. Rouvier, B. Favre, SENSEI-LIF at SemEval-2016 Task 4: Polarity embedding fusion for robust sentiment analysis, *SemEval 2016*, pp. 202-208, June 2016.
- [14] X. Xu, H. Liang, T. Baldwin, UNIMELB at SemEval-2016 Tasks 4A and 4B: An Ensemble of Neural Networks and a Word2Vec Based Model for Sentiment Classification, *SemEval 2016*, pp. 183-189, June 2016.
- [15] S. Rosenthal, N. Farra, P. Nakov, SemEval-2017 Task 4: Sentiment Analysis in Twitter, *SemEval 2017*, 17 pp., 2017.
- [16] M. Cliché, BB twtr at SemEval-2017 Task 4: Twitter Sentiment Analysis with CNNs and LSTMs, *SemEval 2017*.
- [17] H. Hamdan, Senti17 at SemEval-2017 Task 4: Ten Convolutional Neural Network Voters for Tweet Polarity Classification, *SemEval 2017*, pp. 691-694, August 2017.
- [18] S. M. Mohammad, Word affect intensities, *arXiv:1704.08798*, August 2017.
- [19] S.M. Mohammad, F. Bravo-Marquez, Emotion Intensities in Tweets, 6th joint conference on lexical and computational semantics, August 2017.
- [20] S. M. Mohammad, F. Bravo-Marquez, Wassa-2017 shared task on emotion intensity, *WASSA-2017*, pages 34–49, September 2017.
- [21] S. M. Mohammad, F. Bravo-Marquez, M. Salameh, and S. Kiritchenko, SemEval-2018 Task 1: Affect in tweets, *SemEval 2018*, pages 1–17, June 2018.
- [22] Y. Taigman, M. Yang, M. Ranzato, L. Wolf, DeepFace: Closing the Gap to Human-Level Performance in Face Verification, *Conference on Computer Vision and Pattern Recognition*, June 2014.
- [23] S. Antol, A. Agrawal, J. Lu, M. Mitchell, D. Batra, C. L. Zitnick, D. Parikh, VQA: Visual question answering, *Proceedings of the IEEE International Conference on Computer Vision*, pages 2425–2433, December 2015.
- [24] B. Felbo, A. Mislove, A. Søgaard, I. Rahwan, and S. Lehmann, Using millions of emoji occurrences to learn any-domain representations for detecting sentiment, emotion and sarcasm, In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 1615–1625, August 2017.
- [25] V. Duppada, S. Hiray, SeerNet at emoint-2017: Tweet emotion intensity estimator, *WASSA-2017*, pages 205–211, September 2017.
- [26] Y. Kim, Convolutional neural networks for sentence classification, *EMNLP 2014*, August 2014.
- [27] V. Duppada, R. Jain, S. Hiray, SeerNet at SemEval-2018 Task 1: Domain Adaptation for Affect in Tweets, *SemEval 2018*, pages 18–23, June 2018.
- [28] C. Baziotis, N. Athanasiou, A. Chronopoulou, A. Kolovou, G. Paraskevopoulos, N. Ellinas, S. Narayanan, A. Potamianos, NTUA-SLP at SemEval-2018 Task 1: Predicting Affective Content in Tweets with Deep Attentive RNNs and Transfer Learning, *SemEval 2018*, pages 245–255, June 2018.
- [29] J. H. Park, P. Xu, P. Fung, PlusEmo2Vec at SemEval-2018 Task 1: Exploiting emotion knowledge from emoji and #hashtags, *SemEval 2018*, pages 264–272, June 2018.
- [30] G. Gee, E. Wang, psyML at SemEval-2018 Task 1: Transfer Learning for Sentiment and Emotion Analysis, *SemEval 2018*, pages 369–376, June 2018.
- [31] H. Meisheri, L. Dey, TCS Research at SemEval-2018 Task 1: Learning Robust Representations using Multi-Attention Architecture, *SemEval 2018*, pages 291–299, June 2018.