

雑談内容を用いた留学生の日本語能力推定手法の提案

CHEN XINNAN[†] 鈴井 克徳[†] 若林 啓[†]

[†] 筑波大学 図書館情報メディア研究科 〒305-8550 茨城県つくば市春日 1-2

[†] 筑波大学 情報学群 知識情報・図書館学類 〒305-8550 茨城県つくば市春日 1-2

[†] 筑波大学 図書館情報メディア系 〒305-8550 茨城県つくば市春日 1-2

E-mail: †s1821642@s.tsukuba.ac.jp, ††kts-sz@klis.tsukuba.ac.jp, †††kwakaba@slis.tsukuba.ac.jp

概要 我々は雑談システムを活用して、留学生の日本語雑談能力をトレーニングするための手法の研究を行っている。留学生に対する既存の雑談システムの主な問題点は、留学生の日本語能力に合わせて会話できない点である。本研究では、留学生の日本語能力を会話文から測る機能を既存の雑談システムに追加するために、留学生の会話文を用いて留学生の日本語の特徴を抽出し、この特徴を用いて、会話した留学生の日本語能力試験スコアを予測する手法を提案する。日本語能力試験スコアを予測する回帰モデルの特徴量として、日本語能力試験語彙表、文法表の各級の単語と文法が会話文に出現した回数と、ニューラルネットワークを用いて推定される日本語として不自然な箇所数を用いる。実験では、平均平方二乗誤差により、モデルの予測結果の誤差を評価することで、不自然箇所数が一番有効な特徴量であることを示す。

キーワード 機械学習, 対話システム, 日本語能力

Estimation Method of Japanese Language Ability of Foreign Students Using Characteristics in Conversation

Xinnan CHEN[†], Katsunori SUZUI[†], and Kei WAKABAYASHI[†]

[†] Graduate School of Library, Information and Media Studies, University of Tsukuba
1-2 Kasuga, Tsukuba-shi, 305-8550 Japan

[†] College of Knowledge and Library Sciences, University of Tsukuba
1-2 Kasuga, Tsukuba-shi, 305-8550 Japan

[†] Faculty of Library, Information and Media Science, University of Tsukuba
1-2 Kasuga, Tsukuba-shi, 305-8550 Japan

E-mail: †s1821642@s.tsukuba.ac.jp, ††kts-sz@klis.tsukuba.ac.jp, †††kwakaba@slis.tsukuba.ac.jp

Abstract We are conducting research on method to train foreign students' Japanese chat abilities by utilizing chat system. The main problem of existing chat systems for foreign students: It is not possible to chat with foreign students to adapt their Japanese abilities. In this research, in order to add the function to measure foreign student's Japanese ability from the conversation sentences to the existing chat system, we extracted foreign student's Japanese characteristics from foreign student's conversation sentence. We propose a method to predict the Japanese-Language Proficiency Test score of foreign students. As feature value of regression model for predicting the Japanese-Language Proficiency Test score, we used the number of times that each word and grammar of each level of the Japanese Language Proficiency Test Vocabulary Table and Grammar Table appears in the conversation sentence, and the number of unnatural places as Japanese estimated using the neural network. In the experiment, we using evaluating the mean square error to predict result of the model, it shows that the number of unnatural places is the most effective feature in model.

Key words machine learning, dialogue system, japanese language ability

1. はじめに

近年、日本に留学する外国人留学生数が増加している。独立法人 日本学生支援機構によって実施された「国内の高等教育機関等における外国人留学生の在籍状況等について」[1] という調査によると、「平成 28 年 5 月 1 日現在の外国人留学生は 239,287 人（対前年比 30,908 人（15 %）増）であり、留学生数の多い国・地域は中国 98,483 人（対前年比 4,372 人増）、ベトナム 53,807 人（対前年比 14,925 人増）、ネパール 19,471 人（対前年比 3,221 人増）」と報告されている。

留学生が日本に来て、日本語で会話する際に難しいと感じる問題の一つは、対人の緊張感のせいで日本語を用いて会話をうまく進められないということである。会話の練習をするためには、実際に日本語で会話することが有効であるが、初対面の知らない人と会話するのは非常に緊張しやすいことに加えて、異文化の壁により相手が何を表現したいのかが理解できない場合も多く、会話を進められなくなる。このため、留学生の会話能力のトレーニングのために、雑談対話システムを相手にすることが効果的であると考えられる。近年では雑談システムに関する研究が活発に行われている。雑談システム [2] とは、特定の話題やテーマなどに絞らず、人間との自然な会話の成立を目指す対話システムであり、1 人暮らしの単身者や高齢者などとの話し相手としての利用、娯楽目的などの利用が期待されている。

しかし、これらの雑談システムは留学生が直接利用するには、留学生にとって理解しにくい応答文を返すことが問題になる。実際の雑談システムでの例を挙げると、「ね、ところでやっぱ」、「JK の顔を被ったオッサンだからね」、「何だかんだ待つけどね」などは理解しにくい応答である。このような応答がシステムからあると、留学生は理解しにくく、会話を続けられない。留学生は日本語を日本語能力検定試験のために習うため、実際の日本人との会話においても、教科書にある硬い日本語文法表現とは違う柔軟な表現に対してうまく対応できない場合がある。例えば、「イラオコ」、「ググレカス」、「おにゃのこ」、「あーね」、「そうかい」などは、留学生にとって難しい表現である。

このため、留学生にとって理解しにくい文を応答に用いないような、留学生の日本語能力に合わせて応答する雑談システムが必要である。これを実現するためには、現存の雑談システムに、留学生の日本語能力を会話から推定できる機能を追加することが重要である。

本研究では、留学生の日本語能力試験の得点を会話内容から推定する手法を提案する。実際に留学生との会話を行なってデータを収集し、日本語能力試験の得点を会話内容から予測するための訓練データセットを作成した。予測の特徴量として、日本語能力試験の文法表や語彙表に載っている文法、語彙の使用数と、ニューラルネットワークを用いて推定される不自然箇所の数を用いて評価実験を行う。実験では、平均平方二乗誤差により、モデルの予測結果の誤差を評価することで、有効な特徴量を調査するとともに、高い精度で日本語能力試験の得点を予測できることを明らかにする。

2. 関連研究

本研究の関連研究としては、外国人学習者の日本語能力を測るための試験に関する研究、留学生の会話文の中の語彙や文法の間違いを検出する研究、留学生の日本語文を分析して使用されている単語と文法を検出するシステムに関する研究がある。

外国人学習者の日本語能力を測る試験の代表的なものとして、日本語能力試験がある。李ら [3] の「日本語能力試験の新たな取り組み」では、試験の問題でもコミュニケーション能力を重視すべきであると述べており、2010 年から新しく開始された日本語能力試験では、これに対応する採点方式として、項目応答理論 (Item Response Theory, IRT) を導入して得点等化を行うなど、新しい取り組みを行っている。

李ら [3] は近年世界の外国語試験の共通出題動向を三つの点でまとめて、以下のように述べている。一つ目はテストの測定対象が、いわゆる「語彙」や「文法」といった言語の内的知識・構造的知識から「コミュニケーション能力」へとシフトしている点。二つ目は、古典的テスト理論に代わって登場した IRT のような測定理論に基づいて採点などを行う傾向にある点。三つ目は得点の解釈のため、テストの可否や得点以外の参考情報を一般向けに公表する傾向にある点である。このように、日本語能力試験による日本語能力の評価方法には妥当な裏付けがあると考えられることから、本研究では、日本語能力試験の点数を予測の目的変数とする。

これまでの研究で、外国人学習者の日本語文章の誤りを検出する取り組みが進められている。山本ら [5] の「Project Next 日本語校正タスク」では、主な対象として、日本語学習者 (外国人) が執筆した文章の日本語校正に関する研究を行っている。この研究で示された課題は二つある。一つは、間違った日本語文に対して、形態素解析を行うことが難しいため、間違った日本語に対しても頑強な形態素解析を行う手法を検討することである。「～しか～ない～」、「いつも～する」などの、分離表現を把握することである。水本ら [4] は、日本語学習者 (外国人) が執筆した文章では助詞の誤り検出・訂正のみに限定した研究の報告が最も多いことを示している。鈴井ら [17] の研究では、ニューラルネットワークを用いて、日本語文章中の不自然と考えられる箇所を自動で検知する手法を提案している。このような手法で検出した誤りの数の特徴量として利用することで、日本語能力の推定に役立つと考えられる。本研究では特に、鈴井ら [17] の提案した手法を用いて、不自然箇所の検出を行い、その検出数の特徴量として用いる。

3. 提案手法

3.1 データ

本研究では、会話内容から日本語能力検定試験のスコアを予測することが可能かどうかを検証するためのデータとして、留学生に実際に会話を行ってもらい、会話文を収集した。それぞれの留学生からは、日本語能力検定試験の得点も教えてもらった。

対象者は、日本に留学する留学生である。チャットツールで

留学生の会話文に含まれた誤りの数を特徴量として利用するため，本研究では鈴井ら[17]の提案するニューラルネットワークに基づく不自然箇所検出モデルを用いる．このモデル

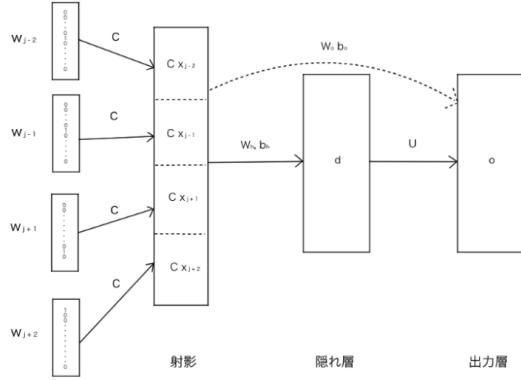


図3 鈴井ら[17]の不自然箇所検出モデル構造図

では、会話文中の各単語 w_j の出現確率を、その周辺の単語 $w_{j-2}, w_{j-1}, w_{j+1}, w_{j+2}$ を特徴量として推定を行う。図3に、鈴井らの不自然箇所検出モデルの構造を示す。

まず各単語を、one-hot 表現と呼ばれる、その単語に割り当てられた索引の要素のみが1、他を0で表現したベクトルで表現する。one-hot 表現により、文章を単語列 $S = w_1, w_2, \dots, w_{n_S}$ と表現する。このとき、 w_j は N 次元のベクトルである。 S の任意の j 番目の単語 w_j の確率を予測するとき、その周辺の単語 $w_{j-2}, w_{j-1}, w_{j+1}, w_{j+2}$ をモデルの入力とする。これらを $N \times P$ の射影行列 C により $c = (Cw_{j-2}, Cw_{j-1}, Cw_{j+1}, Cw_{j+2})$ と連結した1つのベクトルに射影する。隠れ層として、 $P \times H$ の重み行列 W_h と H 次元のバイアスベクトル b_h により $d' = W_h c + b_h$ へとアフィン変換を行う。 d' を \tanh 関数を活性化関数として非線型変換を行い、 d を得る。 d' の k 番目の要素を d'_k 、 d の k 番目の要素を d_k とすると、 $d_k = \tanh d'_k$ と表される。 c を $(n-1)P \times N$ の重み行列 W_o と N 次元のバイアスベクトル b_o によりアフィン変換したベクトルと、 $H \times N$ の重み行列 U によりアフィン変換したベクトルを足し合わせ、 $o' = W_o c + b_o + U d$ を得る。Softmax 関数 $o_k = e^{o'_k} / \sum_{l=1}^N e^{o'_l}$ を用いて、モデルの出力 o を得る。予測対象の単語 w_j に対応する索引を v とすると、この出力における v 次元目の値 o_v が、この文脈における単語 w_j の確率である。

このモデルを、自然な日本語のコーパスを用いて学習を行うことで、前後の単語に対して不自然であると考えられる単語を見つけ出すことができる。本研究では、自然な日本語のコーパスとして、Yahoo! 知恵袋^(注1)における2004年4月1日から2009年4月7日までの質問のうちの3,000,000文章を用いた。

$$P(D_i^{(M)} | D_{i-2}^{(M)}, D_{i-1}^{(M)}, D_{i+1}^{(M)}, D_{i+2}^{(M)}) \quad (1)$$

留学生の会話文に対して不自然箇所検出モデルを用いて各単語の確率を求め、その確率が閾値 θ を超えている単語の数を、

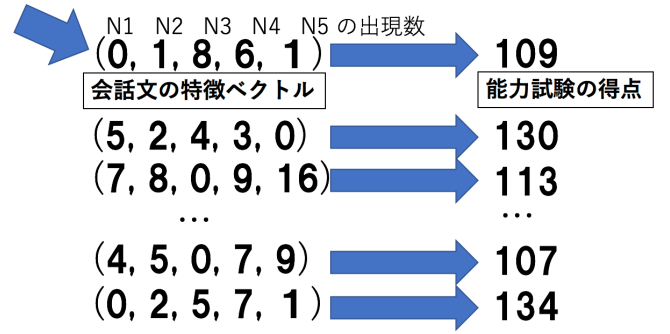


図4 留学生の日本語能力試験の得点の予測例

不自然箇所数の特徴量として用いる。ただし、不自然箇所検出モデルは、単純に低頻度の語彙に対しては、自然な単語であっても低い確率を割り当ててしまう。このため、検出語彙の集合 C を、頻度の高い語彙に制限する。 C の決め方は、Yahoo! 知恵袋における語彙の頻度順に並べて上位 T 件の語彙を C の要素とする。 T を検出対象語彙数と呼ぶ。

留学生の会話文の集合を $D = \{D^{(1)}, D^{(2)}, \dots, D^{(M)}\}$ 、 $D^{(m)} = w_1^m, w_2^m, \dots, w_n^m$ とする。 M は前述の通り発話回数である。 n は会話文 m に含まれる単語数である。留学生の文章に対して不自然箇所検出モデルを用いて計算される、周辺語彙を文脈とした時の各単語 w_j^m の確率を $p(w_j^{(m)} | w_{j-2}^{(m)}, w_{j-1}^{(m)}, w_{j+1}^{(m)}, w_{j+2}^{(m)})$ と表すことにすると、不自然箇所数 e は以下のように求める。

$$e = \sum_{m, i: w_j^{(m)} \in C} \delta \left(p(w_j^{(m)} | w_{j-2}^{(m)}, w_{j-1}^{(m)}, w_{j+1}^{(m)}, w_{j+2}^{(m)}) \geq \theta \right)$$

ただし、 $\delta_{(x)}$ はディラックのデルタ関数であり、述語 x が真の時1、偽の時0とする。予測の特徴量として用いる際には、発話数で割った $\tilde{e} = \frac{e}{M}$ を用いる。

3.3 予測モデル

本研究では複数の留学生のデータからモデルを学習して、留学生の日本語能力試験の得点を予測する。予測例を図4に示す。

3.3.1 線形回帰

変数が x と y の2つの場合を例に挙げる。 x を独立変数、 y を従属変数と呼ぶ。変数 x と y は、

$$y = ax + b \quad (2)$$

という関数によって、関係を表す。このように、データ間の関係を直線で表現することは、特に線形回帰と呼ばれる。回帰の手法として最小二乗法がある。これは誤差を伴う測定値の処理において、その誤差の二乗の和を最小にすることで、最も確からしい関係式を求める方法である。モデル関数を $f(x)$ とするとき、

$$\sum_{i=1}^n \{y_i - f(x_i)\}^2 \quad (3)$$

が最小となるように $f(x)$ を求める。

3.3.2 K-近傍回帰

元々 K-近傍法はクラスのラベルが付加された訓練事例が与

(注1) : <https://chiebukuro.yahoo.co.jp/>

えられているクラス分類の場合に分類したい事例から近い順に k 個の事例を見つけて、これら k 個の事例のうち、多数をしめるクラスに分類する手法であるが、K-近傍法は回帰にも使われる。各データ点での関数値が付加された訓練事例が与えられている回帰の場合、分類したい事例の近い方から順に k 個の事例を見つける。これら、 k 個の事例の関数値を、対応する事例までの距離に対して減少するような重みをつけた、加重平均して推定値とする。次の式で $f(x)$ を次のように推定する。

$$\hat{f}(x) = \frac{1}{k} \sum_{j=1}^k Y_j \quad (4)$$

Y_j とは点 x の k -近傍点 $(X_1, Y_1, \dots, X_k, Y_k)$ を取ってくることである。

4. 実験

4.1 評価方法

13 人（日本語能力 N1 レベル者）のデータに対して提案手法により特徴量抽出を行い、交差検証に基づいて訓練データとテストデータに分ける。各テストセットにおいて、訓練データを用いて学習した回帰モデルが予測するテストデータの日本語能力試験スコアを、平方平均二乗誤差 (RMSE) により評価する。RMSE は常に正の値をとる予測誤差を示す指数である。値が小さいほど予測精度が高いことを表す。計算式は、以下で定義される。

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (5)$$

このとき N は全予測対象数、 y_i は真の値、 \hat{y}_i は予測値である。今回の実験では、全予測対象数は 13 人（日本語能力 N1 レベル者）の日本語能力試験スコアである。

ベースラインとして、機械学習を行わずに、訓練データの日本語能力試験スコアの平均値を予測値とする場合の RMSE を用いる。交差検証には Leave-One-Out 法を用いることとする。つまり、テストデータは 1 人ずつのスコア値であり、残り 12 人のデータを訓練データとする。

本研究では、特徴量として、各レベルの語彙表に含まれる語彙の数 $\tilde{A}_{(1)}, \dots, \tilde{A}_{(5)}$ 、各レベルの文法表に含まれる文法の数 $\tilde{B}_{(1)}, \dots, \tilde{B}_{(5)}$ 、推定された不自然箇所数 \tilde{e} を用いる。どの特徴量が有効であるかを検証するため、今回の実験では予測モデルの特徴量ベクトルとして、以下の 9 つのパターンを設定した。

- $V(5) = (\tilde{A}_{(1)}, \dots, \tilde{A}_{(5)})$ (5 次元)
- $G(5) = (\tilde{B}_{(1)}, \dots, \tilde{B}_{(5)})$ (5 次元)
- $V + G(5) = (\tilde{A}_{(1)} + \tilde{B}_{(1)}, \dots, \tilde{A}_{(5)} + \tilde{B}_{(5)})$ (5 次元)
- $V + G(10) = (\tilde{A}_{(1)}, \dots, \tilde{A}_{(5)}, \tilde{B}_{(1)}, \dots, \tilde{B}_{(5)})$ (10 次元)
- $V + E(6) = (\tilde{A}_{(1)}, \dots, \tilde{A}_{(5)}, \tilde{e})$ (6 次元)
- $G + E(6) = (\tilde{B}_{(1)}, \dots, \tilde{B}_{(5)}, \tilde{e})$ (6 次元)
- $V + G + E(6) = (\tilde{A}_{(1)} + \tilde{B}_{(1)}, \dots, \tilde{A}_{(5)} + \tilde{B}_{(5)}, \tilde{e})$ (6 次元)
- $V + G + E(11) = (\tilde{A}_{(1)} + \tilde{B}_{(1)}, \dots, \tilde{A}_{(5)} + \tilde{B}_{(5)}, \tilde{e})$ (11 次元)
- $E(1) = (\tilde{e})$ (1 次元)




図 5 予測モデルの特徴量に $E(1)$ を用いて、 T と θ を変化させた時の RMSE 値の変化。横軸は閾値 θ であり、縦軸は RMSE である。例えば、100error-linear の線は、線形モデルを用いて $T = 100$ とした時の RMSE の変化を示している。

4.2 評価結果

まず、不自然箇所の検出手法におけるパラメータである、検出対象語彙数 T と閾値 θ の影響を調べるため、予測モデルの特徴量として $E(1)$ （不自然箇所の数のみ）を用いて、 T と θ を変化させた場合の RMSE 値の変化を確認する。この実験結果を図 5 に示す。図 5 を見ると、予測モデルの特徴量に $E(1)$ を用いた場合の RMSE 値は、線形モデルを用いて、 $T = 300$ 、 $\theta = 0.01$ の時に最小になり、その値が 1.08 であることがわかる。

ベースラインの RMSE 値と予測モデルの各特徴量パターンの RMSE 値の比較を表 2 に示す。

表 2 RMSE の比較 ($T = 300, \theta = 0.01$)

特徴量パターン	線形モデル	K-近傍
ベースライン	17.29	
$V(5)$	2.72	2.54
$G(5)$	2.69	2.56
$V + G(5)$	2.12	2.55
$V + G(10)$	5.04	2.57
$V + E(6)$	2.56	2.54
$G + E(6)$	1.31	2.56
$V + G + E(6)$	1.9	2.55
$V + G + E(11)$	2.69	2.54
$E(1)$	1.08	2.87

表 2 は、ベースラインの RMSE 値と、提案手法の各特徴量パターンの RMSE 値の比較結果である。ここでは、検出対象語彙数を $T = 300$ 、閾値を $\theta = 0.01$ としている。ベースラインの RMSE 値は 17.29 であり、予測モデル全ての特徴量パターンがベースラインより大幅に良い。このことから、会話文から抽出した特徴量は、日本語能力試験の得点の推定に大きく寄与していることが分かる。また、予測モデルの各特徴量パターンでは、特徴量の不自然箇所数を追加することによって、線形モデルを用いた予測の RMSE 値が下がる効果が顕著である。

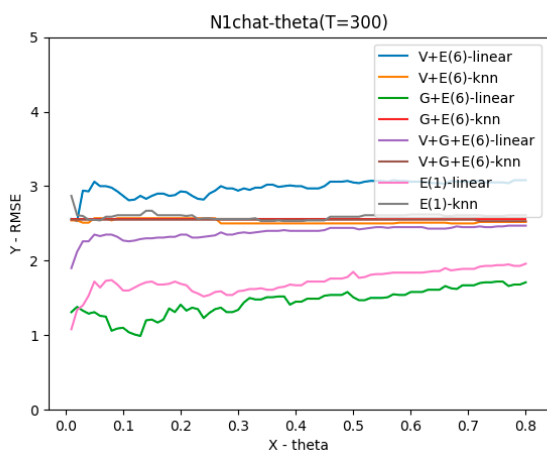


図6 $T=300$, $E(1)$ の特徴量を用いて, θ を変化させた時の RMSE 値

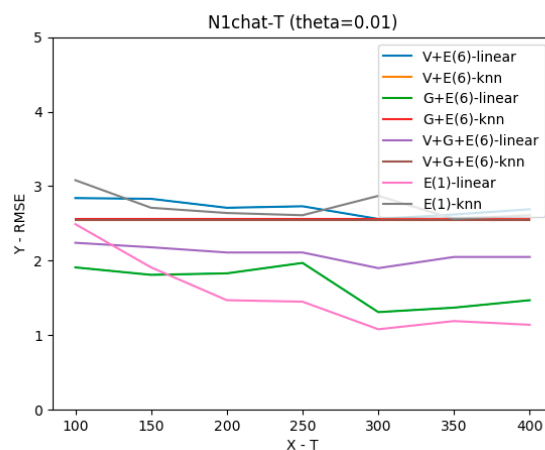


図7 $\theta=0.01$, $E(1)$ の特徴量を用いて, T を変化させた時の RMSE 値

次に, 複数の特徴量を組み合わせた場合に, 検出対象語彙数 T と閾値 θ がどの程度精度に影響するのかを確認するため, 各特徴量パターンについて, T と θ を変化させた時の RMSE の最大値と最小値の差を求めた. 表 3 に, RMSE の最大値と最小値の差を示す. $V + G + E(11)$ の場合は線形回帰モデルの場合の最小値は 0.0 であるが, 最大値は 2426.84 であり, 非常に不安定である. 不自然箇所数の特徴量を含む予測モデルでは, K-近傍回帰モデルは線形回帰モデルより安定しているが, 線形回帰モデルの方がより良い性能であることが分かる.

表 3 T と θ を変化させた時の RMSE の最大値と最小値の差

パターン	線形モデル	K-近傍モデル
$V + E(6)$	0.59	0.07
$G + E(6)$	1.05	0.03
$V + G + E(6)$	0.57	0.02
$V + G + E(11)$	2426.84	0.04
$E(1)$	1.41	0.59

より詳細な実験結果を図 6 と図 7 に示す. RMSE 変化の差が大きい特徴量のパターン $V + G + E(11)$ を除いて, $V + E(6)$, $G + E(6)$, $V + G + E(6)$, $E(1)$ について, RMSE の変化をプロットした. $T = 300$ と固定して, 閾値 θ を 0.01 から 0.8 まで 0.01 ずつ増加させた時の各特徴量パターンの RMSE の変化を図 6 に示す. $\theta = 0.01$ と固定して, T を 100 から 400 まで 50 ずつ増加させた時の各特徴量パターンの RMSE の変化を図 7 に示す.

5. 結 論

本研究では, 留学生の会話から, 会話者の日本語能力試験の得点を推定できることを示した. 特徴量パターンごとの RMSE の比較により, 不自然箇所数を用いた予測モデルが最も良い RMSE を達成できることを示した. 提案手法を用いて留学生の日本語能力を推定することで, 易しい言い回しを用いるなど日本語会話補助ツールとしての雑談システムの開発に寄与できると考えられる.

文 献

- [1] 独立法人 日本学生支援機構. 平成 28 年度 外国人留学生在籍状況調査結果. JLPT. 2017/03.
- [2] 福田 拓也, 若林 啓. 雑談システムにおける Twitter データからの統計的バックチャネル応答抽出手法. 人工知能学会全国大会 (第 31 回). 2017/05.
- [3] 李 在鎬, 川端 一光, 矢澤 理子, 堀川 有美. 日本語能力試験の新たな取り組み. 言語教育評価研究第 2 号. 2011, pp64-72.
- [4] 水本 智也, 小町 守, 永田 昌明, 松本 裕治. 日本語学習者の作文自動誤り訂正のための語学学習 SNS の添削ログからの知識獲得. 人工知能学会論文誌. 2013, vol28, No.5, p420-p432.
- [5] 山本 和英, 鄭育昌. Project Next 日本語校正タスク. Project Next NLP 報告会. 2015.
- [6] 独立法人 日本学生支援機構. 2017 年第 1 回日本語能力試験 実施結果. JLPT. 2017.
- [7] 李 在鎬. 日本語教育のための文章難易度に関する研究. 早稲田日本語教育学. 2016/12, 21pp.1-16.
- [8] Jonathan Waller. JLPT N1, N2, N3, N4 and N5 vocabulary list. JLPT Resources. 2010/11.
- [9] Jonathan Waller. JLPT N1, N2, N3, N4 and N5 grammar list. JLPT Resources. 2010/11.
- [10] 独立法人 日本学生支援機構. N1 N5 : 認定の目安. JLPT. 2012.
- [11] 堀 恵子. 文法項目データベース「はごろも」の海外における利用可能性を探る - 一口頭能力評価と読解教材分析から - . 日本語学習辞書科研 2012 年度第 1 回全体研究集会. 2012/09.
- [12] 堀 恵子. 日本語教育のためのコーパスに基づく文法項目データベース構築と検索システムの公開. 科学研究費助成事業 (科学研究費補助金) 研究成果報告書. 2012.
- [13] 李 在鎬, 砂川 有里子, 長谷部陽一郎. 「日本語教育語彙表と検索システム」. ヨーロッパ日本語教師会 ポスター発表. 2015.
- [14] 砂川 有里子, 李 在鎬, 高原 真理. 日本語学習辞書支援のためのデータベース構築. EAJIS, AJE ヨーロッパ日本語教育シンポジウムパネルセッション. 2014.
- [15] 李 在鎬, 長谷部陽一郎. 中上級学習者のための日本語読み書き支援システム構築に関する研究. 「文章を科学する : 学習者作文分析」ワークショップ. 2017.
- [16] 独立法人 日本学生支援機構. 日本語能力試験結果の見方. JLPT. 2012.
- [17] 鈴井 克徳, 若林 啓. ニューラルネットワークを用いた日本語学習者の文章に置ける不自然箇所検知. WebDB Forum, 2018.